

VGGT : Visual Geometry Grounded Transformer

CVPR 2025 論文重點整理 | 從多視角影像一次預測相機、深度、點雲與對應關係

Jianyuan Wang^{1,2}

Minghao Chen^{1,2}

Nikita Karaev^{1,2}

Andrea Vedaldi^{1,2}

Christian Rupprecht¹

David Novotny²

¹Visual Geometry Group, University of Oxford

²Meta AI



圖 1 | VGGT 的任務概觀。輸入一張、數張到數百張影像，即可共同估計場景幾何。圖像取自原論文。

核心結論

VGGT 將傳統多階段 3D 重建管線，改寫成單一大型 Transformer 的前向推論問題。它不只更快，純前向結果在多項基準上已超越需要全域對齊或 Bundle Adjustment 的既有方法。

論文	作者與單位	公開資訊
VGGT: Visual Geometry Grounded Transformer	Jianyuan Wang 等 Oxford VGG、Meta AI	CVPR 2025 facebookresearch/vggt

閱讀定位：這不是單純的深度估計器，而是企圖成為通用 3D 視覺 backbone 的大型幾何模型。

1 | 它要解決什麼問題？

輸入為觀察同一場景的 N 張 RGB 影像。VGGT 一次輸出每張影像的相機參數、深度、point map 與跨視角追蹤特徵；所有 3D 結果以第一張相機為世界座標參考。

輸出	含義	表示方式
Camera	相機內外參	旋轉四元數 4D + 平移 3D + 視野角 2D
Depth map	各像素到相機的深度	每張影像一張 H×W 圖
Point map	各像素對應的 3D 點	第一張相機座標系中的 3×H×W
Point tracks	同一 3D 點在各視角的位置	跨影像的 2D 對應；不是直接輸出動態 XYZ 軌跡
Uncertainty	深度與 point map 的可信度	像素級 aleatoric uncertainty

關鍵設定

- 第一張影像固定為參考座標；其餘影像順序可任意交換。
- 相機主點假設位於影像中心；第一台相機姿態設為單位旋轉與零平移。
- 輸出彼此具數學關係：相機 + 深度可以反投影為 3D 點，point map 也可反推相機。
- 模型仍同時學習所有輸出，利用多任務監督建立更完整的場景幾何表徵。

與既有路線的差異

方法路線	典型流程	主要代價
傳統 SfM / MVS	匹配 → 三角化 → 全域最佳化 → BA	準確但階段多、速度慢
DUST3R / MAST3R	兩張一組預測 → 多對結果全域融合	多視角時仍需後處理
VGGT	所有影像共同進入 Transformer → 一次輸出	依賴大量訓練資料與模型先驗

直覺上，VGGT

是把一部分原本在測試階段執行的幾何推理與最佳化，提前『蒸餾』進模型參數中。

2 | 模型架構：極少 3D 歸納偏置




Figure 2. **Architecture Overview.** Our model first patchifies the input images into tokens by DINO, and appends camera tokens for camera prediction. It then alternates between frame-wise and global self attention layers. A camera head makes the final prediction for camera extrinsics and intrinsics, and a DPT [57] head for any dense output.

圖 2 | 原論文架構圖。DINO 將影像轉成 tokens；主幹交替使用 Global 與 Frame Attention；不同 heads 輸出相機與密集幾何。

四個主要步驟

步驟	設計	作用
1	DINO patch tokens	取得具泛化力的 2D 視覺特徵
2	Camera token + 4 個 register tokens	承載每張影像的相機資訊；特殊 token 標記第一張影像
3	Alternating-Attention · 預設 $L=24$	交替整合單張內部結構與跨影像全域關係
4	Camera head、DPT head、CoTracker2 式 head	分別預測相機、密集幾何與跨視角點對應

為何採用交替注意力？

Frame-wise attention 先維持單張影像內的空間一致性；Global attention

再讓所有影像交換資訊。消融結果顯示，這比只做 global self-attention 或以 cross-attention 為主更準。

ETH3D point map	Accuracy ↓	Completeness ↓	Overall ↓
Cross-Attention	1.287	0.835	1.061
Global Self-Attention only	1.032	0.621	0.827
Alternating-Attention	0.901	0.518	0.709

3 | 真正有效的兩個設計洞見

洞見 A | 訓練時讓相關任務彼此約束

相機、深度與 point map 雖可互相轉換，但共同監督仍會提高準確率。模型不只是多頭輸出，而是在共享 backbone 中學到一致的場景表示。

訓練設定	Accuracy ↓	Completeness ↓	Overall ↓
沒有相機 loss	1.042	0.627	0.834
沒有深度 loss	0.920	0.534	0.727
沒有追蹤 loss	0.976	0.603	0.790
相機 + 深度 + 追蹤完整監督	0.901	0.518	0.709

洞見 B | 訓練時多預測，推論時拆解複雜任務

直接 point-map head 並不是最佳輸出。由預測深度搭配預測相機進行反投影，ETH3D Overall error 從 0.709 降到 0.677。這表示將複雜問題拆成較簡單、結構明確的子問題，仍能帶來好處。

ETH3D 方法	Accuracy ↓	Completeness ↓	Overall ↓	時間
DUST3R + 全域對齊	1.167	0.842	1.005	約 7 秒
MASt3R + 全域對齊	0.968	0.684	0.826	約 9 秒
VGGT 直接 Point	0.901	0.518	0.709	約 0.2 秒
VGGT Depth + Camera	0.873	0.482	0.677	約 0.2 秒

工程含義

- 可依需求使用不同輸出頭，或用幾何關係進行交叉檢查。
- 不確定度可用來剔除低可信度點，或決定哪些區域需要後續最佳化。
- 若追求最高精度，仍可把 VGGT 當作 BA 的高品質初始化。

4 | 量化結果：速度與精度同時提升

相機姿態 | 10 張隨機影像，時間在單張 H100 GPU 上量測

方法	RealEstate10K AUC@30 ↑	CO3Dv2 AUC@30 ↑	時間
DUST3R	67.7	76.7	約 7 秒
MASt3R	76.4	81.8	約 9 秒
VGGsfm v2	78.9	83.4	約 10 秒
VGGT 純前向	85.3	88.2	約 0.2 秒
VGGT + BA	93.5	91.8	約 1.8 秒

多視角深度 | DTU，VGGT 不使用測試時的真實相機

方法	已知 GT 相機	Accuracy ↓	Completeness ↓	Overall ↓
GeoMVSNet	是	0.331	0.259	0.295
DUST3R	否	2.677	0.805	1.741
VGGT	否	0.389	0.374	0.382

雙視角匹配 | ScanNet-1500

方法	AUC@5 ↑	AUC@10 ↑	AUC@20 ↑
DKM	29.4	50.7	68.3
RoMa	31.8	53.4	70.9
VGGT	33.9	55.2	73.4

怎麼解讀？

- 純前向版本已超過多個需要迭代後處理的系統，顯示模型確實學到多視角幾何推理。
- 加上 BA 後仍能明顯進步：RealEstate10K 由 85.3 提升至 93.5。傳統幾何沒有消失，而是轉為精修角色。
- RealEstate10K 未出現在這些方法的訓練資料中；其優勢支持 VGGT 的跨資料集泛化主張。

5 | 定性結果：模型先驗帶來泛化，也帶來風險




Figure 3. **In-the-wild comparison of our predicted 3D points to DUST3R.** As shown in the top row, our method successfully predicts the geometric structure of an oil painting, while DUST3R predicts a slightly distorted plane. In the second row, our method correctly recovers a 3D scene from two images with no overlap, while DUST3R fails. The third row provides a challenging example with repeated textures while our prediction is still high-quality. We do not include examples with more than 32 frames, as DUST3R then runs out of memory.

圖 3 | 原論文與 DUST3R 的比較。VGGT 在油畫、兩張無重疊影像，以及重複紋理場景中仍能形成完整結構。

論文展示的三種困難案例

- 單張油畫：VGGT 推測出具有立體結構的場景；DUST3R 較接近平面。
- 兩張無重疊影像：沒有直接特徵對應時，VGGT 仍能透過語義與場景先驗連結兩個視角。
- 32 張沙漠 / 金字塔影像：面對重複、低紋理區域仍生成較穩定的點雲，論文報告約 0.6 秒。

重要判讀

無重疊影像也能產生完整 3D 結構，既是 VGGT 最吸引人的能力，也是最需謹慎之處。缺乏幾何對應時，輸出會更依賴訓練資料學到的先驗，因此可能『看起來合理』，卻不一定受到觀測充分約束。

- 對測量、工程與機器人安全場景，應搭配不確定度、重投影誤差或 BA 驗證。
- 對快速預覽、內容製作及弱重疊資料，這種強先驗反而極具實用價值。

6 | 下游任務：從重建器走向 3D Backbone

預訓練特徵可移植到其他 3D 任務




Figure 4. **Qualitative Examples of Novel View Synthesis.** The top row shows the input images, the middle row displays the ground truth images from target viewpoints, and the bottom row presents our synthesized images.

Method	Known Input Cam	Size	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
LGM [72]	✓	256	21.44	0.832	0.122
GS-LRM [103]	✓	256	29.59	0.944	0.051
LVSM [36]	✓	256	31.71	0.957	0.027
Ours-NVS*	✗	224	30.41	0.949	0.033

Table 7. **Quantitative comparisons for view synthesis on**

圖 4 | Novel View Synthesis。模型根據四張輸入影像合成新視角；原圖亦列出與已知相機方法的比較。

- Novel view synthesis：不提供輸入影像的相機參數，仍在 GSO 上得到 30.41 PSNR、0.949 SSIM、0.033 LPIPS。

6.2 | 剛體與動態點追蹤



圖 5 | 上：無時間順序的靜態場景跨視角追蹤；下：以 VGGT 預訓練特徵強化 CoTracker 的動態追蹤。

- 動態點追蹤：以 VGGT 預訓練 backbone 替換 CoTracker 特徵抽取器並微調；TAP-Vid RGB-S 的 δ_{vis} avg 由 78.9 提升到 84.0。

7 | 限制、風險與最終評價

使用限制與實驗解讀

限制	影響
主模型假設靜態、同一場景	真正的動態追蹤仍需額外架構與微調
主點固定在影像中心，未建模完整鏡頭畸變	特殊鏡頭、裁切或非標準相機可能受影響
ETH3D 使用 Umeyama 對齊	結果不同絕對公尺尺度完全正確
速度於 H100 上測量	不能直接套用到一般 GPU、手機或邊緣裝置
NVS 使用內部資料集	完整重現性與跨方法公平性需保留判讀
BA 仍可提升結果	VGGT 更像強力初始化與通用 backbone，而非完全取代幾何

最終評價

VGGT 的關鍵貢獻不是單一指標，而是以統一、簡潔的 Transformer 同時處理多項核心 3D 幾何任務。它把 3D 重建從複雜管線推向大型前向模型，也揭示了未來較實際的混合路線：神經網路快速產生高品質幾何，再由傳統方法進行可信度檢查與精修。

圖像來源：Wang et al., “VGGT: Visual Geometry Grounded Transformer,” CVPR 2025。本文為學術閱讀摘要，數據與圖號依原論文整理。